

1. 数据挖掘(Data Mining)实验课III实验报告

0.1. 分析说明

0.1.1. 马尔科夫链 (Markov Chain)

马尔科夫链是一种随机过程，其核心特性是无记忆性，即未来状态只依赖于当前状态，而与之前的历史状态无关。天气状态序列被视作一个马尔科夫链，其中每个状态之间的转移概率可以通过历史数据来估计。

0.1.2. 概率向量的表示和序列共现信息

天气状态的转移概率向量通过天气状态间的序列共现信息捕捉其“语义”特征，在这个上下文中，“语义”指的是天气状态的统计特性和它们之间的动态关系。如果两个天气状态在时间序列中具有相似的转移概率分布，它们的特性可能相似。

0.1.3. 分布式表示和相似性度量

转移概率向量是分布式假设的一个体现，即如果两个状态具有相似的转移概率分布，它们的“语义”可能相似，向量表示是通过统计转移概率来实现的。

0.1.4. 数据降维

使用了一个投影矩阵来将天气状态的概率向量从高维空间映射到二维空间，这样做的目的是为了在二维平面上可视化不同天气状态之间的关系，同时揭示天气状态间的相似性和差异性。

0.2. 关键代码

计算每种天气状态转移到其他状态的概率向量

```
1  # 构建转移次数的字典
2  transition_counts = defaultdict(Counter)
3
4  # 统计转移次数
5  for i in range(len(weather_sequence) - 1):
6      current_state = weather_sequence[i]
7      next_state = weather_sequence[i + 1]
8      transition_counts[current_state][next_state] += 1
9
10 # 计算概率向量
11 transition_probabilities = {}
12 total_transitions = {}
13 for state in weather_states:
14     total_transitions[state] = sum(transition_counts[state].values())
15     transition_probabilities[state] = np.array([transition_counts[state]
16 [target_state] / total_transitions[state]
17 if total_transitions[state] >
0 else 0
for target_state in
weather_states])
```

遍历天气序列，通过增加 `transition_counts[current_state][next_state]` 的计数计算了每种天气状态转移到下一个状态的次数。

概率向量是通过将每种状态转移到特定状态的次数除以该状态的总转移次数得到的。


计算概率向量的投影结果

```
1 # 计算每种天气状态概率向量的投影结果
2 projected_results = {}
3 for state, prob_vector in transition_probabilities.items():
4     projected_vector = np.dot(prob_vector, projection_matrix)
5     projected_results[state] = projected_vector
6
7 x_coords = [result[0] for result in projected_results.values()]
8 y_coords = [result[1] for result in projected_results.values()]
```

遍历 `transition_probabilities` 字典，使用 `np.dot` 函数将概率向量与投影矩阵相乘对每种天气状态的概率向量进行投影，得到该天气状态在二维空间中的位置。

0.3. 实验结果

```
1 Transition probabilities for Sunny:
2   Sunny: 0.1667
3   Rainy: 0.1667
4   Cloudy: 0.3333
5   Cloudy to Sunny: 0.0000
6   Thunderstorm: 0.3333
7
8 Transition probabilities for Rainy:
9   Sunny: 0.0000
10  Rainy: 0.1429
11  Cloudy: 0.5714
12  Cloudy to Sunny: 0.1429
13  Thunderstorm: 0.1429
14
15 Transition probabilities for Cloudy:
16  Sunny: 0.2500
17  Rainy: 0.2500
18  Cloudy: 0.1667
19  Cloudy to Sunny: 0.1667
20  Thunderstorm: 0.1667
21
22 Transition probabilities for Cloudy to Sunny:
23  Sunny: 0.2222
24  Rainy: 0.2222
25  Cloudy: 0.2222
26  Cloudy to Sunny: 0.1111
27  Thunderstorm: 0.2222
28
29 Transition probabilities for Thunderstorm:
30  Sunny: 0.0000
31  Rainy: 0.1000
32  Cloudy: 0.1000
33  Cloudy to Sunny: 0.5000
34  Thunderstorm: 0.3000
```



0.3.1. 结果分析

1. 相似性判断:

- Cloudy to Sunny 和 Cloudy在图中的位置比较接近，这表明它们在转移概率上具有相似性，意味着多云转晴和单纯的多云状态在天气变化模式上有很多共同点。
- Cloudy和Thunderstorm在图中也相对较近，可能表明它们在某些转移概率上具有相似性。

2. 差异性判断:

- Thunderstorm 与其他天气状态相比，在图中的位置较远，尤其是在 Projection Dimension 1 方向上，这表明它在投影维度上与其他天气状态有较大差异，这可能意味着雷暴天气的转移概率特征与其他状态有明显不同，例如，雷暴可能更少直接转变为晴天，而是更可能转变为多云或雨天。
- Rainy和Sunny分布在图的对角线上，这可能反映了它们在天气状态转换上的差异。雨天和晴天可能是天气变化的两个极端，雨天可能不容易直接转变为晴天，而是通过多云等中间状态过渡。